

DETECÇÃO DE PARKINSON ATRAVÉS DE DESENHOS: COMPARAÇÃO ENTRE SUPPORT VECTOR MACHINES E MULTILAYER PERCEPTRONS.

Gessyca de Cássia Leonel Moreira¹

Este artigo apresenta um estudo sobre a detecção da doença de Parkinson usando desenhos de espirais como base de dados. Duas técnicas de classificação foram comparadas: Support Vector Machines (SVM) e Multilayer Perceptrons. A análise considerou a projeção das imagens em um vetor unidimensional e a projeção das imagens em uma matriz, levando em conta os componentes de cor, para classificar os desenhos e distinguir entre indivíduos saudáveis e aqueles com um possível diagnóstico da doença. Os resultados obtidos mostraram que o SVM com um kernel RBF com a projeção da imagem como uma matriz obteve melhor desempenho na classificação. Essas abordagens podem ser úteis para o diagnóstico precoce da doença e contribuir para o tratamento adequado dos pacientes.

Palavras-Chave: Detecção de Parkinson, classificação de imagens, support vector machines, SVM, multilayer perceptrons, aprendizagem de máquina.

This article presents a study on the detection of Parkinson's disease using spiral drawings as a database. Two classification techniques were compared: Support Vector Machines (SVM) and Multilayer Perceptrons. The analysis considered the projection of images into a one-dimensional vector and the projection of images into a matrix, taking into account color components, to classify the drawings and distinguish between healthy individuals and those with a possible diagnosis of the disease. The results obtained showed that SVM with an RBF kernel and the image projection as a matrix achieved better performance in classification. These approaches can be useful for early diagnosis of the disease and contribute to appropriate patient treatment.

Keywords: Parkinson's detection, image classification, support vector machines, SVM, multilayer perceptrons, machine learning.

¹ Graduanda em Sistema da Informação; Instituto Federal de Minas Gerais - IFMG; R. Afonso Sardinha, 90 - Pioneiros, Ouro Branco - MG. Email:gessycadclm@gmail.com.

1. INTRODUÇÃO

A doença de Parkinson é uma condição neurodegenerativa crônica que afeta o sistema nervoso central, causando tremores, rigidez muscular e dificuldades de coordenação motora. O diagnóstico precoce é fundamental para garantir um tratamento adequado e melhorar a qualidade de vida dos pacientes. Nesse contexto, o uso de técnicas de detecção por meio de desenhos pode ser uma abordagem promissora.

Neste estudo, utilizamos desenhos de espirais como base de dados para a detecção de Parkinson. Nosso objetivo foi comparar o desempenho de duas técnicas de classificação: SVM e Multilayer Perceptron. Para isso, realizamos a projeção das imagens em um vetor unidimensional e em uma matriz, para comparação dos resultados e levando em consideração os componentes de cor. A classificação foi feita com base nesses vetores, visando distinguir entre indivíduos saudáveis e aqueles com diagnóstico de Parkinson.

2. MATERIAIS E MÉTODOS

2.1 Base de dados

Utilizamos dois conjuntos de dados: um conjunto de treino e um conjunto de teste. O conjunto de treino era composto por 196 desenhos de indivíduos com Parkinson e 196 desenhos de indivíduos saudáveis. O conjunto de teste continha 48 desenhos de indivíduos com Parkinson e 48 desenhos de indivíduos saudáveis. Abaixo temos dois desenhos que foram utilizados na nossa base de dados. O desenho da esquerda foi realizado por um indivíduo diagnosticado com a doença, enquanto o da direita foi feito por um indivíduo saudável.




Figura 1. Desenhos realizados por indivíduo com diagnóstico da doença e por indivíduo saudável, respectivamente.

Fonte: Deep Learning-aided Parkinson's Disease Diagnosis from Handwritten Dynamics, 2016.

2.2 Processamento das imagens

Antes de criar os algoritmos de classificação, foi necessário normalizar a base de dados. Para isso, utilizamos dois algoritmos um de projeção das imagens em um vetor unidimensional e outro em uma matriz, levando em consideração os componentes de cor em ambos. Os dados foram então armazenados em dois arquivos de extensão .csv, separados por vírgula. Cada item do vetor estava associado à classificação da imagem, que poderia ser "healthy" (saudável) ou "parkinson" (com diagnóstico da doença).

Estudos anteriores, têm destacado a importância da extração de características relevantes dos desenhos para classificação. Nesse sentido, os componentes de cor têm sido considerados como informações valiosas. Portanto, seguimos essa abordagem em nosso estudo.

2.2 Aprendizagem supervisionada

A aprendizagem supervisionada é uma abordagem fundamental na área de inteligência artificial. Nesse tipo de aprendizagem, um modelo é treinado com exemplos rotulados, nos quais são fornecidos pares de entrada e saída esperada.

A principal vantagem da aprendizagem supervisionada é sua capacidade de generalização, permitindo que o modelo faça previsões precisas para dados não vistos anteriormente.

Em resumo, a aprendizagem supervisionada desempenha um papel crucial na inteligência artificial, fornecendo uma base sólida para a construção de modelos capazes de fazer previsões precisas.

2.3 Classificação SVM

O SVM (Support Vector Machine) é um algoritmo de classificação que busca encontrar um hiperplano de separação otimizado para distinguir entre diferentes classes de dados.

2.4 Classificação Multilayer Perceptron

Os Multilayer Perceptrons são redes neurais artificiais com camadas ocultas, capazes de

aprender representações complexas dos dados de entrada para realizar a classificação de imagens.

3. RESULTADOS

3.1 SVM

Os resultados obtidos foram avaliados por meio de métricas de desempenho, como a taxa de classificação correta, a taxa de classificação incorreta, o índice Kappa, o erro absoluto médio, o erro quadrático médio e os erros relativos absolutos e quadráticos.

Durante nossos experimentos sistemáticos, conduzimos testes utilizando diferentes classificações e comparando a eficácia de diversos kernels. Os kernels avaliados foram o Linear Kernel, o RBF Kernel e o Normalized Poly Kernel. O Linear Kernel foi definido como a fórmula abaixo(1).

$$K(x, y) = \langle x, y \rangle \quad (1)$$

O RBF Kernel como a fórmula abaixo (2).

$$K(x, y) = e^{-(0.01 * \langle x-y, x-y \rangle^2)} \quad (2)$$

E o Normalized Poly Kernel como a fórmula abaixo (3).

$$K(x, y) = \frac{\langle x, y \rangle^2}{(\langle x, x \rangle^2 * \langle y, y \rangle^2)^{1/2}} \quad (3)$$

Além disso, exploramos diferentes valores de camadas e neurônios para a classificação Multilayer Perceptron, sendo eles 50, 100 e 200. Após analisarmos os resultados, chegamos a um possível melhor modelo.

Analisando os resultados dos experimentos com os diferentes kernels e suas respectivas métricas de desempenho, podemos determinar qual foi o melhor modelo.

3.1.1 Projeção das imagens em um vetor unidimensional

Para o Linear Kernel, tivemos uma taxa de classificação correta de 54.0984% e uma taxa de classificação incorreta de 45.9016%. A estatística Kappa foi de 0.082, o erro absoluto médio foi de 0.459 e o erro quadrático médio foi de 0.6775.

Já para o RBF Kernel, observamos uma taxa de classificação correta de 50% e uma taxa de classificação incorreta também de 50%. A estatística Kappa foi de 0, o erro absoluto médio foi de 0.5 e o erro quadrático médio foi de 0.7071.

Por fim, o Normalized Poly Kernel apresentou a melhor performance, com uma taxa de classificação correta de 63.9344% e uma taxa de classificação incorreta de 36.0656%. A estatística Kappa foi de 0.2787, o erro absoluto médio foi de 0.3607 e o erro quadrático médio foi de 0.6005.

3.1.2 Projeção das imagens em uma matriz

Para o Linear Kernel, tivemos uma taxa de classificação correta de 83.3333% e uma taxa de classificação incorreta de 16.6667%. A estatística Kappa foi de 0.6667, o erro absoluto médio foi de 0.1667 e o erro quadrático médio foi de 0.4082.

Já para o Normalized Poly Kernel apresentou a melhor performance, com uma taxa de classificação correta de 79.1667% e uma taxa de classificação incorreta de 20.8333%. A estatística Kappa foi de 0.5833, o erro absoluto médio foi de 0.2083 e o erro quadrático médio foi de 0.600.

Por fim, o RBF Kernel, observamos uma taxa de classificação correta de 91.6667% e uma taxa de classificação incorreta também de 8.3333%. A estatística Kappa foi de 0.8333, o erro absoluto médio foi de 0.0833 e o erro quadrático médio foi de 0.2887.

3.1.3 Conclusão

Com base nos resultados obtidos, o Normalized Poly Kernel se mostrou o melhor modelo, quando tratado da projeção das imagens em um vetor unidimensional, apresentando uma taxa de classificação correta mais alta e métricas de erro relativamente menores em comparação com o Linear Kernel e o RBF Kernel. Mas a taxa de classificação correta do Normalized Poly Kernel para vetor unidimensional é inferior a taxa da RBF Kernel para a projeção em matriz que obteve uma taxa de sucesso em 91.6667%.

3.2 Multilayer Perceptron

E por fim analisamos os resultados dos experimentos com diferentes números de camadas ocultas para a classificação Multilayer Perceptron, podemos determinar qual foi o melhor modelo.

3.2.1 Projeção das imagens em um vetor unidimensional

Com 50 camadas ocultas, tivemos uma taxa de classificação correta de 79.1667% e uma taxa de classificação incorreta de 20.8333%. A estatística Kappa foi de 0.5833, o erro absoluto médio foi de 0.2137 e o erro quadrático médio foi de 0.4402.

Ao aumentar para 100 camadas ocultas, observamos uma taxa de classificação correta de 66.3934% e uma taxa de classificação incorreta de 33.6066%. A estatística Kappa foi de 0.3279, o erro absoluto médio foi de 0.3605 e o erro quadrático médio foi de 0.474.

Por fim, ao utilizar 200 camadas ocultas, obtivemos uma taxa de classificação correta de 62.2951% e uma taxa de classificação incorreta de 37.7049%. A estatística Kappa foi de 0.2459, o erro absoluto médio foi de 0.3754 e o erro quadrático médio foi de 0.6064.

3.2.2 Projeção das imagens em uma matriz

Com 50 camadas ocultas, tivemos uma taxa de classificação correta de 68.8525% e uma taxa de classificação incorreta de 31.1475%. A estatística Kappa foi de 0.377, o erro absoluto médio foi de 0.3566 e o erro quadrático médio foi de 0.4712.

Ao aumentar para 100 camadas ocultas, observamos uma taxa de classificação correta de 79.1667% e uma taxa de classificação incorreta de 20.8333%. A estatística Kappa foi de 0.5833, o erro absoluto médio foi de 0.2128 e o erro quadrático médio foi de 0.4389.

Por fim, ao utilizar 200 camadas ocultas, obtivemos uma taxa de classificação correta de 79.1667% e uma taxa de classificação incorreta de 20.8333%. A estatística Kappa foi de 0.5833, o erro absoluto médio foi de 0.2065 e o erro quadrático médio foi de 0.4306.

3.2.3 Conclusão

Portanto, com base nos resultados obtidos com a classificação da projeção da imagens em um vetor unidimensional, o modelo com 50 camadas ocultas foi o que apresentou a melhor performance, com uma taxa de classificação correta mais alta, estatística Kappa mais significativa e métricas de erro relativamente menores em comparação aos modelos com 100 e 200 camadas ocultas. E quando comparamos os resultados obtidos com a projeção em uma matriz e obtemos a mesma taxa de classificação correta da análise anterior nos modelos de 100 e 200 camadas ocultas, porém o modelo com 200 camadas ocultas apresenta uma métricas de erro inferior aos outros.

4. CONCLUSÃO

Neste estudo, realizamos a detecção da doença de Parkinson usando desenhos de espirais como base de dados. Comparamos as técnicas de SVM e Multilayer Perceptron para classificar os desenhos e distinguir entre indivíduos saudáveis e aqueles com Parkinson. Os resultados mostraram que o SVM com um kernel polinomial normalizado e o Multilayer Perceptron com 50 camadas ocultas obtiveram os melhores resultados, quando olhamos para a projeção em um vetor unidimensional, porém quando olhamos a projeção em uma matriz observamos que o o SVM com kernel RBF obteve uma taxa de classificações corretas de quase 92% enquanto o Multilayer Perceptron obteve a mesma taxa que a classificação com vetor unidimensional e 50 camadas ocultas.

Essas abordagens têm o potencial de auxiliar no diagnóstico precoce da doença, contribuindo para um tratamento adequado dos pacientes. No entanto, é importante ressaltar a necessidade de mais pesquisas, para validar e aprimorar esses modelos, incluindo o uso de conjuntos de dados maiores e a consideração de outros parâmetros relevantes.

5. REFERÊNCIAS

C. R. PEREIRA;S. A. T. WEBER;C. HOOK;G. H. ROSA;J. P. PAPA. Deep Learning-aided Parkinson's Disease Diagnosis from Handwritten Dynamics, 2016. Disponível em:

<<https://wwwp.fc.unesp.br/~papa/pub/datasets/Handpd/>>. Acesso em: 10 jul. 2023.

K. S. MADER. Parkinson's Drawings, 2017. Disponível em: <<https://www.kaggle.com/datasets/kmader/parkinsons-drawings>>. Acesso em: 10 jul. 2023.

COPPING, BEN. Inteligência Artificial. Rio de Janeiro, 2012.

G. C. L. MOREIRA. Repositório com código fonte da pesquisa, 2023. Disponível em: <<https://github.com/Geessyca/parkinson-detection>>. Acesso em: 15 jul. 2023.